Raspagem de dados via Rvest



Meu primeiro projeto de raspagem de dados

Meu primeiro fracasso com raspagem de dados

Rvest

Como conseguir o rvest

```
install.packages("rvest")
```

Comparação Rvest com BeautifulSoup

No **BeautifulSoup**, nossa configuração inicial é assim:

```
# load packages
from bs4 import BeautifulSoup
import requests

# connect to webpage
resp = requests.get("https://bsi.unir

# get BeautifulSoup object
soup = BeautifulSoup(resp.content)
```

Em comparação, no **rvest**:

```
# load rvest package
library(rvest)
# get HTML object
dados_html <- read_html("https://bsi.
```

Como procurar por tags HTML específicas

No BeautifulSoup:

```
links = soup.find_all("a")
```

No Rvest:

```
links <- dados_html %>%
  html_nodes("a")%>%
  html_attr("href")
```

No **rvest**, usamos o operador **%>%**.

Como extrair uma lista de todos os objetos

No **BeautifulSoup**, usamos o método **find_all** para extrair uma lista de todos os objetos de uma *tag* específica de uma página da *web*.

```
# get all div tags
soup.find_all("div")

# get all h1 tags
soup.find_all("h1")
```

No **rvest**, podemos obter tags específicas de HTML usando a função *html_nodes*.

```
# scrape all div tags
html_data %>% html_nodes("div")

# scrape header h1 tags
html_data %>% html_nodes("h1")
```

Como raspar dados do site do BSI com o Rvest?

Provavelmente será algo parecido com isso.

```
link<-"https://bsi.uniriotec.br/bancos-de-dados-i-tin0120/"
pagina <- read_html(link)
r1 <- pagina %>% rvest::html_nodes("h1") %>% html_text()
r4 <- pagina %>% rvest::html_nodes("h4") %>% html_text()
p  <- pagina %>% rvest::html_nodes("p")  %>% html_text()
```

Outros pacotes do R interessantes:

1. RSelenium: R Bindings for 'Selenium WebDriver'
2. XML: Tools for Parsing and Generating XML Within R and S-Plus
3. xml2: Parse XML
4. htmltidy: Tidy Up and Test XPath Queries on HTML and XML Content
5. seleniumPipes: R Client Implementing the W3C WebDriver Specification

Referências para criação desse slide

BeautifulSoup vs. Rvest